

# Analyse en Composantes Principales (ACP)

Rachid EL MAAZOUZ

Août 2018

## 1 Approche géométrique

### 1.1

L'intérêt de centrer et réduire les données de chaque variable est d'étudier leurs variations par rapport à une valeur de référence (Moyennes et variances).

Soit  $A = (a_{ij})_{1 \leq i \leq n, 1 \leq j \leq p} \in \mathbb{R}^{n \times p}$  la matrice des données où la  $i$ -ème ligne représente les données du  $i$ -ème pays pour chaque  $1 \leq i \leq n$ .

On définit la matrice identité  $I_n$  de  $\mathbb{R}^{n \times n}$  et la matrice  $J_n \in \mathbb{R}^{n \times n}$  comme suit:

$$J = \begin{pmatrix} 1/n & 1/n & \dots & 1/n \\ 1/n & 1/n & \dots & 1/n \\ \vdots & \vdots & \ddots & \vdots \\ 1/n & 1/n & \dots & 1/n \end{pmatrix}$$

L'idée est de centrer et réduire chaque colonne de la matrice A. Pour ce faire un ensemble de transformations seront appliquées sur la matrice de données A.

Soit I la matrice identité de taille n :  $I = \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix}$ , l'idée est de centrer les valeurs de

chaque variable (colonne) autour de la moyenne des valeurs de cette variable, pour cela on doit calculer une matrice T qui comprend les moyennes de chaque variable sur la colonne qui lui correspond.

Soit J la matrice de taille n dont tous les coefficients sont  $1/n$  :  $J = \begin{pmatrix} 1/n & 1/n & \dots & 1/n \\ 1/n & 1/n & \dots & 1/n \\ \vdots & \vdots & \ddots & \vdots \\ 1/n & 1/n & \dots & 1/n \end{pmatrix}$

La matrice J permet de calculer les moyennes sur chaque colonne. En effet, la matrice:

$$J^*A = \begin{pmatrix} 1/n & 1/n & \dots & 1/n \\ 1/n & 1/n & \dots & 1/n \\ \vdots & \vdots & \ddots & \vdots \\ 1/n & 1/n & \dots & 1/n \end{pmatrix} * \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & \dots & \dots & a_{np} \end{pmatrix} = \begin{pmatrix} \sum_{k=1}^n a_{k1}/n & \sum_{k=1}^n a_{k2}/n & \dots & \sum_{k=1}^n a_{kp}/n \\ \sum_{k=1}^n a_{k1}/n & \sum_{k=1}^n a_{k2}/n & \dots & \dots \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{k=1}^n a_{k1}/n & \sum_{k=1}^n a_{k2}/n & \dots & \sum_{k=1}^n a_{kp}/n \end{pmatrix}$$

donne une matrice de taille (n,p) dont les colonnes portent les moyennes de chaque variable (colonnes

de A).

La nouvelle matrice centrée à considérer  $M = A - J * A = (I - J) * A$

Maintenant procédons à la réduction de la nouvelle matrice M. Il suffit de diviser ses valeurs par l'écart type calculé sur chaque colonne.

Soit  $N$  la matrice carrée de taille d, définie par:  $N = \begin{pmatrix} e_{ij} \end{pmatrix}_{i=1, j=1}^{n, p}$  tel que:  $e_{ii} = 1/\sqrt{\sum_{k=1}^n m_{ki}^2}$ , 0

sinon

Calculons le produit  $X = M * N$ :

$$X = M * N = \begin{pmatrix} m_{11} & m_{12} & \dots & m_{1d} \\ m_{21} & m_{22} & \dots & \\ \vdots & \vdots & \ddots & \vdots \\ m_{n1} & \dots & \dots & m_{nd} \end{pmatrix} * \begin{pmatrix} e_{11} & 0 & \dots & 0 \\ 0 & e_{22} & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & e_{dd} \end{pmatrix} = \begin{pmatrix} m_{11} * e_{11} & m_{12} * e_{22} & \dots & m_{1d} * e_{dd} \\ m_{21} * e_{11} & m_{22} * e_{22} & \dots & \dots \\ \vdots & \vdots & \vdots & \vdots \\ m_{n1} * e_{11} & m_{n2} * e_{22} & \dots & m_{nd} * e_{dd} \end{pmatrix}$$

Au final, les colonnes de la matrice  $X$  sont les colonnes de la matrice  $M$  divisées par l'écart type calculé sur chaque colonne correspondante.  $X$  est la matrice centrée réduite de la matrice originale  $A$ .

## 1.2

Calculons  $I_{D_u}(X) = \sum_{k=1}^n \|\vec{p}_{D_u}(x_i)\|^2$

$$\begin{aligned} I_{D_u}(X) &= \sum_{k=1}^n \|\vec{p}_{D_u}(x_i)\|^2 \\ &= \sum_{k=1}^n \langle x_i, u \rangle^2 \\ &= \sum_{k=1}^n (u^t \cdot x_i)^2 \\ &= \sum_{k=1}^n (u^t \cdot x_i)(u^t \cdot x_i) \\ &= \sum_{k=1}^n (u^t \cdot x_i)(x_i^t \cdot u) \\ &= \sum_{k=1}^n u^t \cdot (x_i \cdot x_i^t) \cdot u \\ &= u^t \cdot \left[ \sum_{k=1}^n (x_i \cdot x_i^t) \right] \cdot u \end{aligned} \tag{1}$$

Avec la matrice  $\Sigma = \sum_{k=1}^n (x_i \cdot x_i^t)$ , l'équation (1) peut s'écrire comme suit:

$$I_{D_u}(X) = u^t \cdot \Sigma \cdot u$$

L'intérêt de calcul de la projection  $I_{D_u}(X)$  est de savoir les valeurs de  $u$  qui permettent de maximiser  $I_{D_u}(X)$ .

Considérons le Lagrangien  $L(\lambda, u) = I_{D_u}(X) - \lambda.(u^t.u - 1)$ , avec la condition  $u^t.u = 1$ .

Soit  $L(\lambda, u) = u^t.\Sigma.u - \lambda.(u^t.u - 1)$  :

$$\begin{aligned}\frac{\partial L(\lambda, u)}{\partial u} = 0 &\Rightarrow 2.\Sigma.u - 2.\lambda.u = 0 \\ &\Rightarrow \Sigma.u = \lambda.u\end{aligned}$$

Donc la valeur maximale sous contrainte  $u^t.u = 1$  de  $I_{D_u}(X)$  est atteinte sur les vecteurs propres de la matrice  $\Sigma$  puisque diagonalisable et ses valeurs propres sont positives ou nulles (matrice symétrique et définie positive donc). Ces vecteurs propres correspondent aux valeurs propres  $\lambda_i$  de la matrice  $\Sigma$ .

Pour visualiser les points dans un plan  $R^3$ , on prend les 3 premières projections qui correspondent aux 3 grandes valeurs propres de la matrice  $\Sigma$ .




Figure 1: Représentation en base PCA




Figure 2: Représentation en base canonique de  $\mathbb{R}^3$

La dispersion des points sur la base canonique est plus forte que sur celle de base générée par les 3 premiers vecteurs propres de la matrice  $\Sigma$ , e qui confirme le principe de la méthode PCA: visualiser le maximum de points dans un espace minimal.